VIETNAM NATIONAL UNIVERSITY, HO CHI MINH CITY
UNIVERSITY OF SCIENCE
FACULTY OF INFORMATION TECHNOLOGY

Báo cáo đồ án 1

Topic: Intelligent Cloud-Based Log Analytics & BI System

Course: Nhập môn điện toán đám mây

Prepared by

Nguyễn Minh Hiếu	23120124
Nguyễn Minh Tú	23120101
Nguyễn Xuân Duy	23120121

Ngày 28 tháng 4 năm 2026

Mục lục

I Giới thiệu **2**

II Kiến trúc hệ thống **3**

1 Luồng dữ liệu 3

2 Vai trò các thành phần 3

III Chi tiết triển khai **5**

1 Giai đoạn 1: Bảo mật và Cấu hình Môi trường 5

2 Giai đoạn 2: Nhập liệu dữ liệu với Pub/Sub 6

3 Giai đoạn 3: Xử lý với Cloud Functions và AI 7

4 Giai đoạn 4: Phân tích với BigQuery và BigQuery ML 9

5 Giai đoạn 5: Trực quan hóa dữ liệu với Looker Studio 10

IV Kết quả **13**

1 Thống kê tổng quan 13

2 Kết quả đánh giá mô hình BigQuery ML 13

3 Quan sát chính từ pipeline 13

4 Hình ảnh minh họa 14

I Giới thiệu

Đồ án này xây dựng hệ thống phân tích dữ liệu đám mây toàn diện cho một startup truyền thông, nhằm tối ưu hóa việc theo dõi hoạt động website và hành vi khách hàng.

Quy trình vận hành bắt đầu từ việc mô phỏng và truyền tải dữ liệu qua lớp thu nạp serverless, kết hợp AI để phân tích feedback người dùng. Toàn bộ dữ liệu được lưu trữ tại BigQuery, phục vụ việc huấn luyện mô hình dự báo (BigQuery ML) và trực quan hóa báo cáo trên Looker Studio.

II Kiến trúc hệ thống

1 Luồng dữ liệu

Hệ thống xử lý dữ liệu theo quy trình sau:

1. **Tạo dữ liệu hoạt động**: File `log_simulator.py` tạo ra các sự kiện hoạt động tổng hợp của website, mô phỏng hành vi người dùng thực tế như xem sản phẩm, thêm vào giỏ hàng, và phản hồi.

2. **Nhận sự kiện**: Pub/Sub nhận từng sự kiện và lưu trữ tạm thời cho đến khi có consumer sẵn sàng xử lý. Điều này đảm bảo không có sự kiện nào bị mất trong quá trình truyền tải.

3. **Kích hoạt xử lý**: Cloud Function được kích hoạt tự động khi một pesan mới xuất hiện trong Pub/Sub, bắt đầu quy trình xử lý dữ liệu.

4. **Phân tích cảm xúc**: Hàm kiểm tra xem sự kiện có chứa phản hồi của người dùng hay không. Nếu cần phân tích cảm xúc, nó gửi dữ liệu tới Natural Language API để xác định độ tích cực/tiêu cực của phản hồi.

5. **Lưu trữ dữ liệu**: Hàm thêm điểm cảm xúc vào bản ghi và ghi toàn bộ dữ liệu vào BigQuery, tạo thành một kho dữ liệu trung tâm cho tất cả các hoạt động.

6. **Huấn luyện mô hình**: BigQuery ML đọc bảng dữ liệu được lưu trữ và sử dụng nó để huấn luyện mô hình dự đoán mua hàng (`purchase_prediction`), giúp dự đoán hành vi của khách hàng.

7. **Trực quan hóa dữ liệu**: Looker Studio đọc cùng một bảng dữ liệu từ BigQuery để xây dựng các biểu đồ và bảng thông tin tương tác, cung cấp cái nhìn sâu sắc về các xu hướng và mẫu hoạt động.

Quy trình này tạo thành một vòng lặp liên tục, cho phép hệ thống vừa xử lý dữ liệu thời gian thực vừa tích lũy kiến thức từ dữ liệu lịch sử để cải thiện độ chính xác của dự đoán.

2 Vai trò các thành phần

Thành phần	**Vai trò**
`log_simulator.py`	Tạo ra các bản ghi hoạt động giả lập. Là nguồn gốc của pipeline, mô phỏng hành vi người dùng thực tế (xem sản phẩm, thêm vào giỏ hàng, để lại phản hồi).
Pub/Sub	Hàng đợi tin nhắn bất đồng bộ giữa bộ mô phỏng và bộ xử lý. Đảm bảo không có tin nhắn nào bị mất khi hàm xử lý đang bận.
Cloud Function	Xử lý từng tin nhắn khi nó đến. Làm sạch dữ liệu, gọi các dịch vụ AI khi cần, và chuẩn bị bản ghi để lưu trữ.
Natural Language API	Dịch vụ phân tích văn bản dựa trên AI. Chuyển đổi văn bản phản hồi người dùng thành điểm cảm xúc (sentiment score).
BigQuery	Kho lưu trữ dữ liệu trung tâm. Lưu các bản ghi hoạt động đã được làm giàu dữ liệu trong bảng `analytics_ds.website_logs`.
BigQuery ML	Huấn luyện mô hình học máy trực tiếp bên trong BigQuery. Sử dụng dữ liệu lưu trữ để dự đoán hành vi mua hàng của khách hàng.
Looker Studio	Trực quan hóa dữ liệu. Kết nối với BigQuery để hiển thị dữ liệu dưới dạng biểu đồ, bảng thông tin, và báo cáo dễ đọc.

III Chi tiết triển khai

1 Giai đoạn 1: Bảo mật và Cấu hình Môi trường

Bước đầu tiên là chuẩn bị môi trường Google Cloud để pipeline có thể chạy một cách an toàn. Chúng em tạo một dự án riêng biệt, kích hoạt các API cần thiết, và tạo một tài khoản dịch vụ có tên `cloud-function-sa` cho hàm được triển khai.
Các API sau được bật cho dự án:

- Cloud Pub/Sub API
- Cloud Functions API
- BigQuery API
- Cloud Natural Language API

Các vai trò chính được gán cho tài khoản dịch vụ `cloud-function-sa` là:

- **Pub/Sub Subscriber** — cho phép hàm nhận sự kiện từ trigger Pub/Sub
- **BigQuery Data Editor** — cho phép hàm chèn các bản ghi được làm giàu dữ liệu vào `analytics_ds.website_logs`
- **Cloud Functions Invoker** — cho phép hàm chạy trong môi trường triển khai
- **Cloud Natural Language API User** — cho phép truy cập API phân tích cảm xúc nếu cần thiết trong quá trình triển khai hoặc chạy

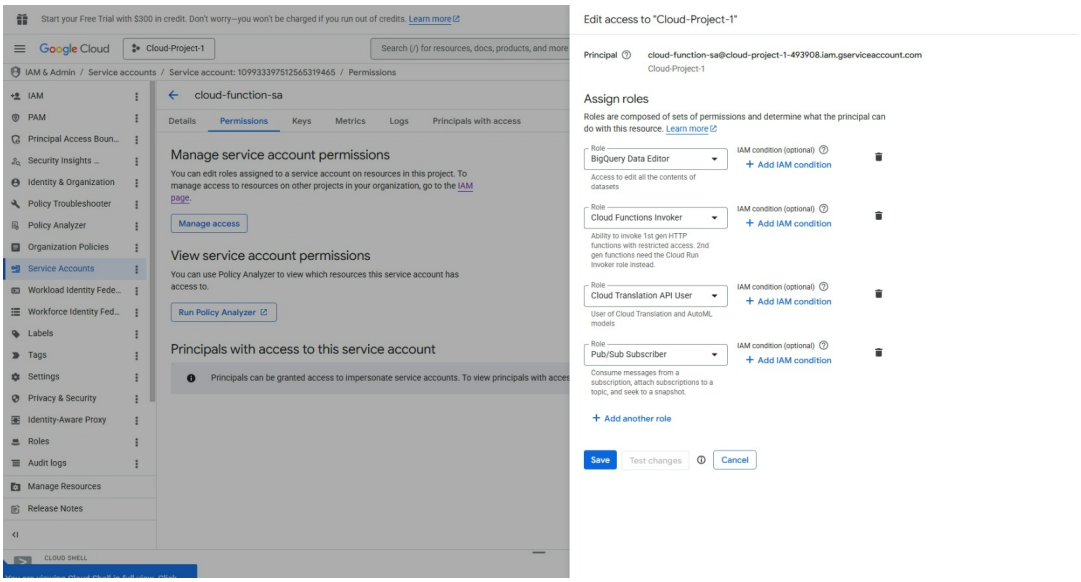

Hình 1: Tài khoản dịch vụ `cloud-function-sa`

2 Giai đoạn 2: Nhập liệu dữ liệu với Pub/Sub

Chúng em tạo Pub/Sub topic `website-logs` và subscription `website-logs-sub` trong Google Cloud Console. Những thành phần này tạo thành tầng nhập liệu cho pipeline.

Tạo topic và subscription

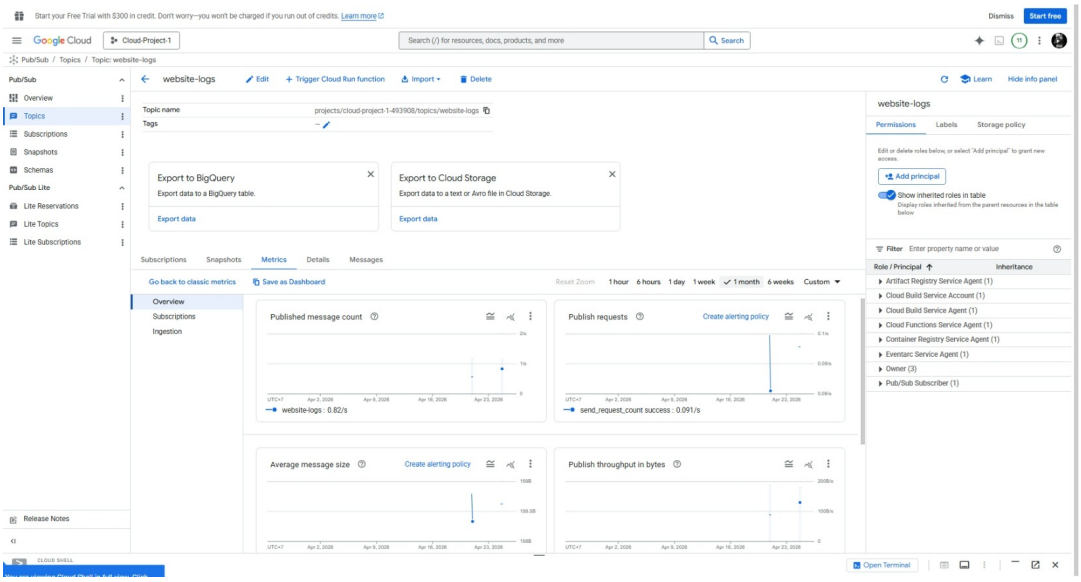

Hình 2: Pub/Sub topic `website-logs`

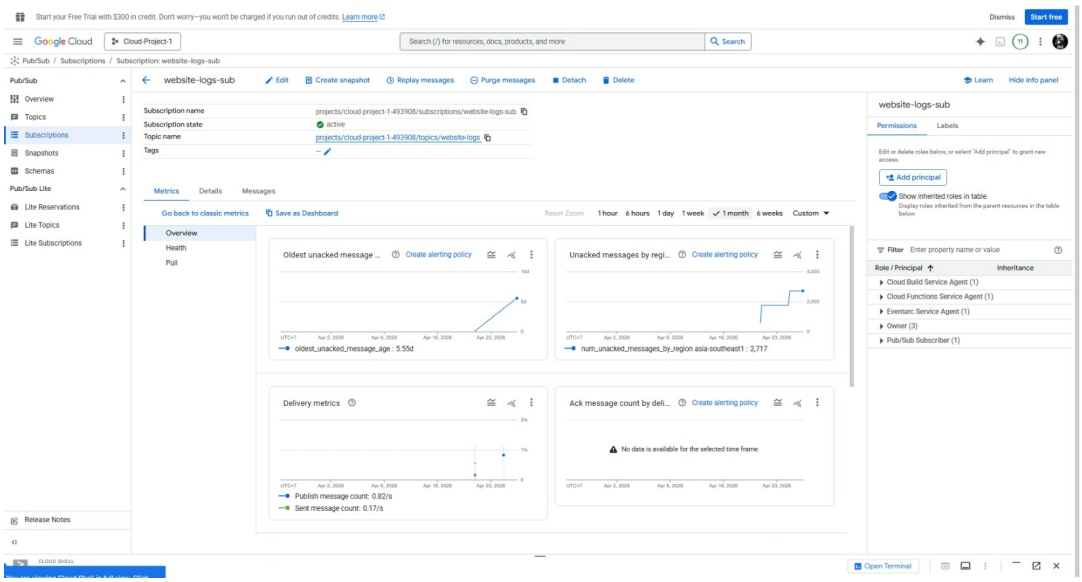

Hình 3: Pub/Sub subscription `website-logs-sub`

Tạo log simulator

Chúng em tạo file `log_simulator.py` trong Cloud Shell tạo ra các sự kiện website tổng hợp với các trường: `timestamp`, `user_id`, `action`, `page`, `response_time_ms`, và tùy chọn `feedback` (khả năng 30%). Script sử dụng Google Cloud Pub/Sub client library, được cài đặt qua:

```
pip install google-cloud-pubsub
```

Chạy simulator

Chúng em đã chạy simulator trong Cloud Shell:

```
python log_simulator.py
```

Simulator đã xuất bản tin nhắn liên tục. Chúng em đã xác minh dữ liệu đang chảy bằng cách kéo tin nhắn từ subscription `website-logs-sub` trong Pub/Sub console và xác nhận tất cả các trường đều có mặt và được định dạng chính xác.

3 Giai đoạn 3: Xử lý với Cloud Functions và AI

Ở giai đoạn này, chúng em triển khai tầng xử lý dưới dạng dịch vụ Cloud Function có tên `process-website-logs` và kết nối với Pub/Sub để mỗi tin nhắn mới từ `website-logs` sẽ tự động kích hoạt xử lý.

Quy trình thiết lập được thực hiện theo các bước sau:

1. Mở Cloud Run functions từ khu vực Cloud Functions trong Google Cloud Console.
2. Tạo một Python function bằng inline editor.
3. Thiết lập cấu hình dịch vụ cốt lõi:
   - Service name: `process-website-logs`
   - Runtime: Python (phiên bản mới nhất có trong console)
   - Billing mode: Request-based
   - Minimum instances: 0
4. Cấu hình trigger trong Eventarc Trigger:
   - Event provider: Cloud Pub/Sub
   - Event type: `google.cloud.pubsub.topic.v1.messagePublished`
   - Topic: `website-logs`
   - Region: cùng region với function khi có thể
5. Cập nhật thiết lập bảo mật runtime:
   - Runtime service account: `cloud-function-sa`
   - Function entry point: `process_log`

Sau khi hoàn tất phần cấu hình, chúng em cập nhật mã nguồn trong inline editor:

- `main.py`: nhận dữ liệu Pub/Sub, làm giàu sentiment bằng Natural Language API, và ghi dữ liệu đã làm giàu vào BigQuery.
- `requirements.txt`: khai báo các thư viện phụ thuộc cần khi deploy.

```
functions-framework==3.*
google-cloud-bigquery==3.21.0
google-cloud-language==2.13.0
```

Tiếp theo, chúng em deploy function và kiểm tra deployment trong logs. Một lần chạy thành công cho thấy các bản ghi được xử lý và chèn vào `analytics_ds.website_logs`, xác nhận Giai đoạn 3 đã hoàn tất và sẵn sàng cho các bước phân tích downstream.

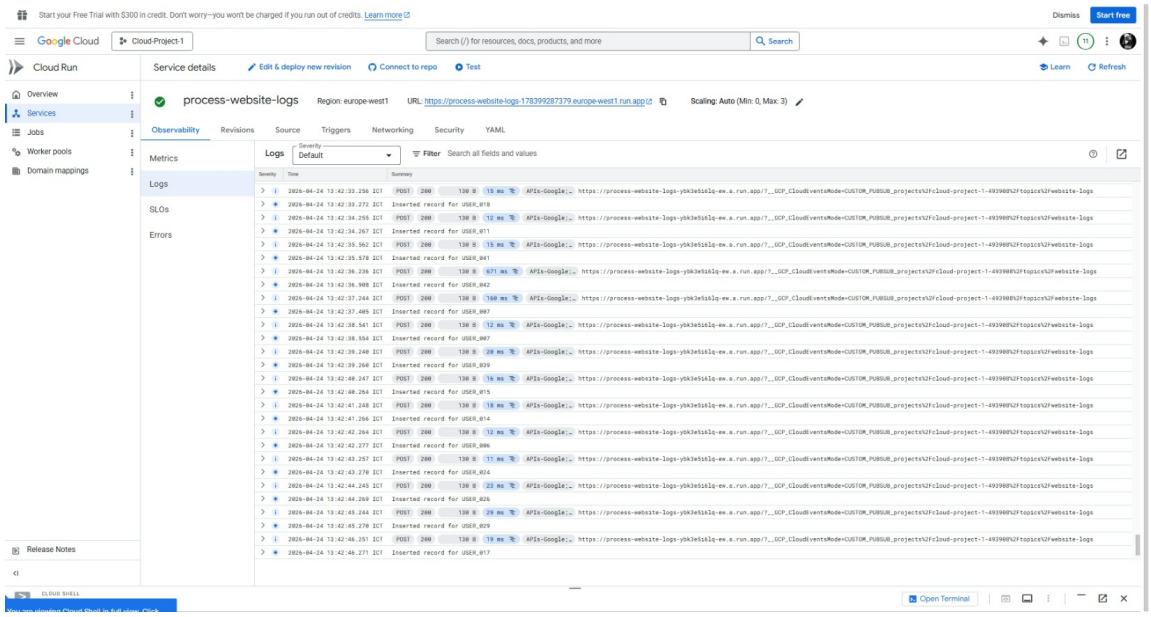

Hình 4: Quá trình bản ghi được xử lý bởi Cloud Function `process-website-logs`

4 Giai đoạn 4: Phân tích với BigQuery và BigQuery ML

Chúng em tạo BigQuery dataset `analytics_ds` và bảng `website_logs` để lưu dữ liệu đã làm giàu từ Cloud Function. Schema của bảng được khai báo như sau:

```
[
    { "name": "timestamp", "type": "TIMESTAMP", "mode": "NULLABLE" },
    { "name": "user_id", "type": "STRING", "mode": "NULLABLE" },
    { "name": "action", "type": "STRING", "mode": "NULLABLE" },
    { "name": "page", "type": "STRING", "mode": "NULLABLE" },
    { "name": "response_time_ms", "type": "INTEGER", "mode": "NULLABLE" },
    { "name": "feedback", "type": "STRING", "mode": "NULLABLE" },
    { "name": "sentiment_score", "type": "FLOAT", "mode": "NULLABLE" },
    { "name": "processed_at", "type": "TIMESTAMP", "mode": "NULLABLE" }
]
```

Sau khi bảng có đủ dữ liệu, chúng em huấn luyện mô hình logistic regression trong BigQuery ML với tên `purchase_prediction`. Câu lệnh SQL dùng để huấn luyện mô hình như sau:

```sql
CREATE OR REPLACE MODEL `analytics_ds.purchase_prediction`
OPTIONS(
    model_type='logistic_reg',
    input_label_cols=['is_purchase'],
    auto_class_weights=TRUE
) AS
SELECT
    IF(action='purchase',1,0) AS is_purchase,
    sentiment_score,
    response_time_ms
FROM `analytics_ds.website_logs`
WHERE sentiment_score IS NOT NULL;
```

Truy vấn trên sử dụng `action` để tạo nhãn `is_purchase`, sau đó huấn luyện mô hình với hai đặc trưng đầu vào là `sentiment_score` và `response_time_ms`.

5 Giai đoạn 5: Trực quan hóa dữ liệu với Looker Studio

Giai đoạn cuối cùng của pipeline là trực quan hóa kết quả phân tích. Chúng em kết nối Looker Studio trực tiếp với bảng `analytics_ds.website_logs` để xây dựng một dashboard thương mại tương tác.

Kết nối Looker Studio và BigQuery

1. Truy cập Looker Studio (looker.studio)
2. Tạo một báo cáo mới (New Report)
3. Chọn BigQuery làm nguồn dữ liệu
4. Chọn dự án GCP, dataset `analytics_ds` và bảng `website_logs`
5. Xác nhận kết nối

Xây dựng các biểu đồ chính

Chúng em xây dựng ba biểu đồ chính để trình bày thông tin kinh doanh quan trọng:

1. **Biểu đồ Gauge (Sentiment Trung Bình)**

- Loại: Gauge (thước đo)
- Số liệu: Giá trị trung bình của `sentiment_score`
- Mục đích: Hiển thị độ hài lòng chung của khách hàng
- Các bước thực hiện:
  - Thêm một biểu đồ Gauge vào dashboard
  - Chọn trường `sentiment_score` làm số liệu
  - Cấu hình phạm vi hiển thị từ 0 đến 1
  - Chọn phép tính AVG cho `sentiment_score`

2. **Biểu đồ Chuỗi Thời Gian (Lưu lượng theo Giờ)**

- Loại: Time series (đường biểu đồ)
- Trục X: Thời gian (timestamp)
- Trục Y: Số lượng sự kiện
- Mục đích: Cho thấy xu hướng lưu lượng truy cập theo thời gian
- Các bước thực hiện:
  - Thêm một biểu đồ chuỗi thời gian vào dashboard
  - Chọn trường `timestamp` làm trục X và đếm số lượng sự kiện làm trục Y
  - Cấu hình để trục X nhóm theo giờ

3. **Biểu đồ Tròn (Phân bố Hành động)**

- Loại: Pie chart (biểu đồ tròn)
- Dữ liệu: Số lượng từng loại hành động (`action`)
- Mục đích: So sánh tỷ lệ các hành động người dùng
- Các bước thực hiện:
  - Thêm một biểu đồ tròn vào dashboard
  - Chọn trường `action` làm phân loại và đếm số lượng sự kiện làm giá trị
  - Cấu hình để hiển thị tỷ lệ phần trăm cho mỗi loại hành động

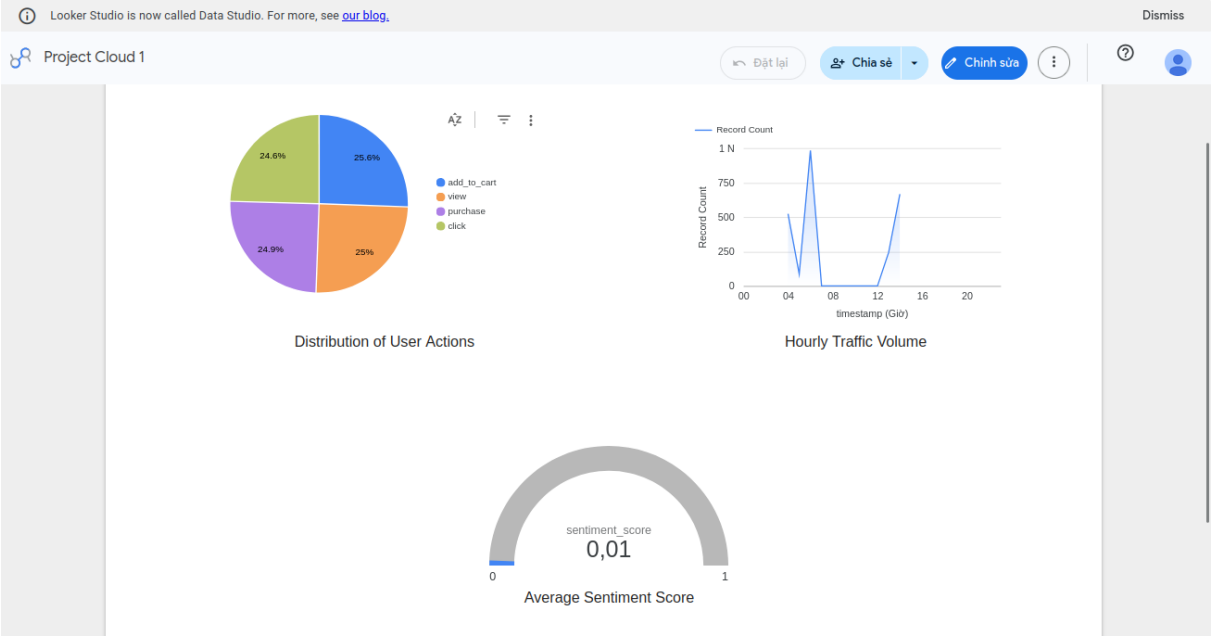

Hình 5: Tổng quan dashboard Looker Studio với ba biểu đồ chính và các bộ lọc

IV Kết quả

1 Thống kê tổng quan

Sau khi chạy pipeline hoàn chỉnh với dữ liệu mô phỏng, hệ thống tạo ra các số liệu sau:

Chỉ số	**Giá trị**
Tổng số bản ghi xử lý	2504
Bản ghi có feedback	771
Điểm sentiment trung bình	0.01
Tỷ lệ hành động mua hàng	24.9%

Bảng 1: Thống kê tổng quan dữ liệu sau khi xử lý

2 Kết quả đánh giá mô hình BigQuery ML

Mô hình logistic regression `purchase_prediction` được huấn luyện trên dữ liệu đã làm giàu. Kết quả đánh giá mô hình sử dụng `ML.EVALUATE` như sau:

Chỉ số Hiệu Năng	**Giá trị**
Precision	0.0
Recall	0.0
Accuracy	0.758
ROC AUC	0.552
F1-Score	0.0

Bảng 2: Kết quả đánh giá mô hình dự đoán hành vi mua hàng

Những chỉ số này phản ánh một thực tế quan trọng về tập dữ liệu đầu vào. Với mức ROC AUC chỉ đạt khoảng 0.55 và các chỉ số Precision/Recall ở mức thấp, mô hình hiện tại chưa thể phân loại chính xác hành vi mua hàng. Tuy nhiên, điều này cung cấp những insight kỹ thuật rất giá trị.

3 Quan sát chính từ pipeline

Từ quá trình triển khai và kết quả thu được, chúng em có những nhận xét sau:

1. **Tính ổn định và hiệu năng của Data Pipeline**

   Trình mô phỏng tạo ra luồng sự kiện liên tục, Pub/Sub tiếp nhận và định tuyến không mất mát dữ liệu, và Cloud Function xử lý thành công từng tin nhắn.

2. **Chất lượng dữ liệu và Giới hạn của Machine Learning**

   Sự sụt giảm hiệu năng của mô hình BQML là một minh chứng rõ nét cho nguyên lý "Garbage In, Garbage Out". Qua phân tích mã nguồn mô phỏng, các biến đầu vào (`response_time_ms`, `feedback`) và biến mục tiêu (`action`) được sinh ra hoàn toàn ngẫu nhiên và độc lập. Do không có mối tương quan logic thực tế nào tồn tại trong tập dữ liệu thô, thuật toán Logistic Regression không thể tìm ra quy luật phân loại. Điều này bài học lớn về việc chất lượng dữ liệu thu thập quyết định trực tiếp đến sự thành bại của mô hình AI.

3. **Hiệu quả của công cụ trực quan hóa (Looker Studio)**

   Dashboard Looker Studio đã kết nối trực tiếp với BigQuery và cập nhật theo thời gian thực một cách hiệu quả, tiện lợi:

   - Lưu lượng truy cập qua các khung giờ hoạt động của trình mô phỏng.
   - Phân bố của các hành động người dùng
   - Thống kê điểm số cảm xúc trung bình (sentiment gauge) toàn cục.

   Việc tự động hóa báo cáo này giúp giảm thiểu thao tác thủ công và cung cấp cái nhìn trực quan ngay lập tức cho các bên liên quan.

4 Hình ảnh minh họa

Dưới đây là các hình ảnh chính từ quá trình triển khai:

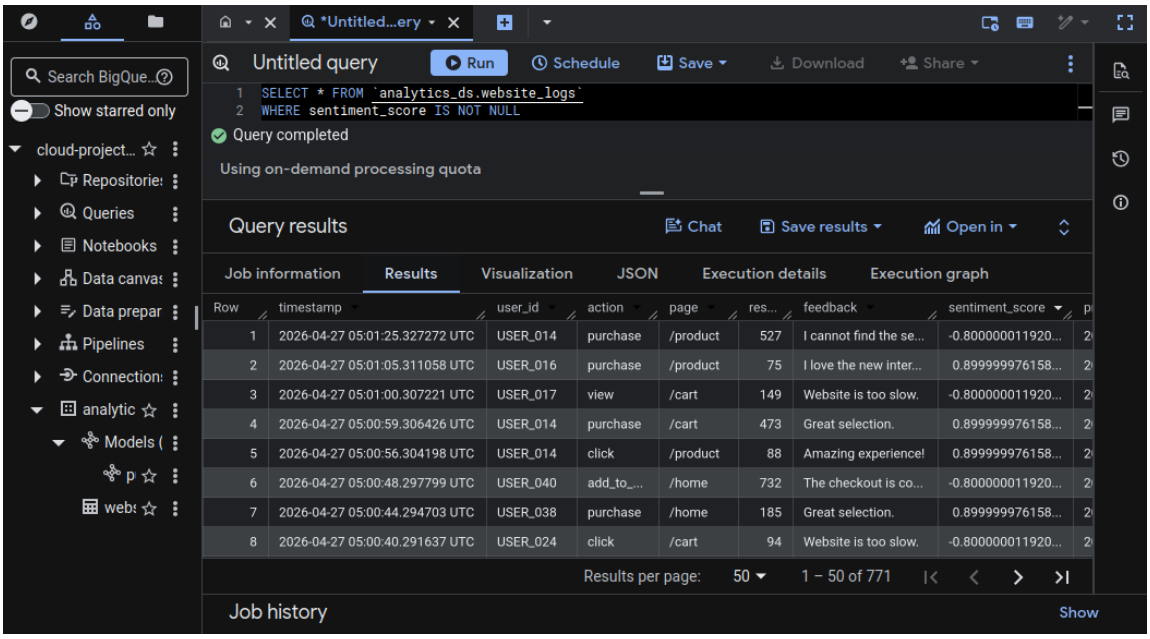

Hình 6: Bảng `website_logs` trong BigQuery với các bản ghi đã xử lý và trường sentiment_score

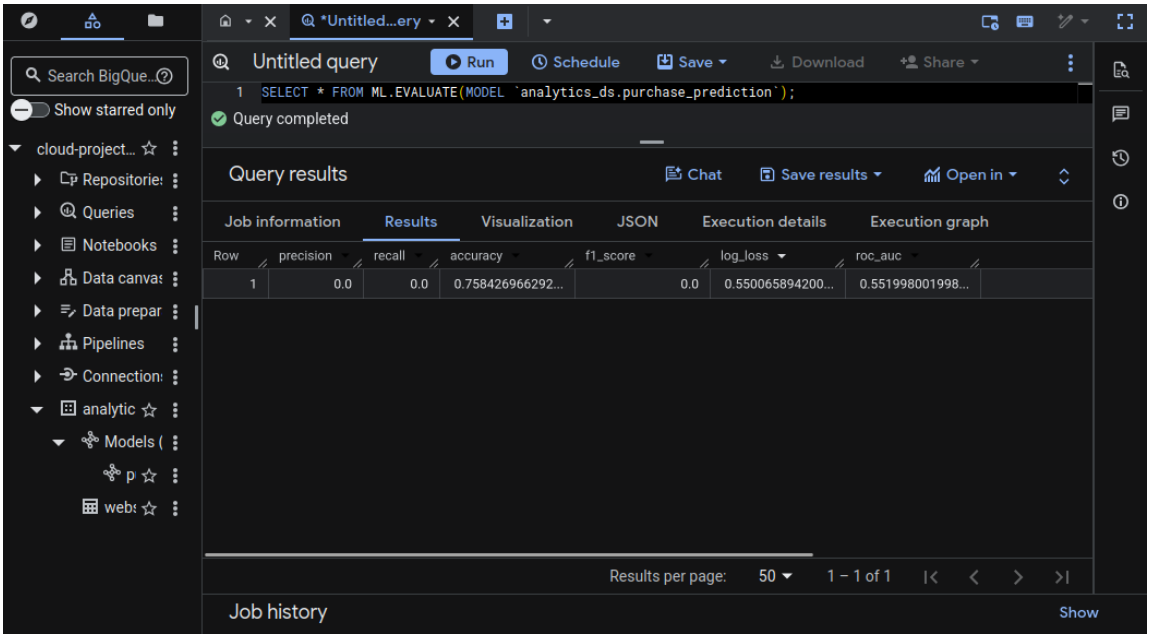

Hình 7: Kết quả đánh giá mô hình `purchase_prediction` từ `ML.EVALUATE`

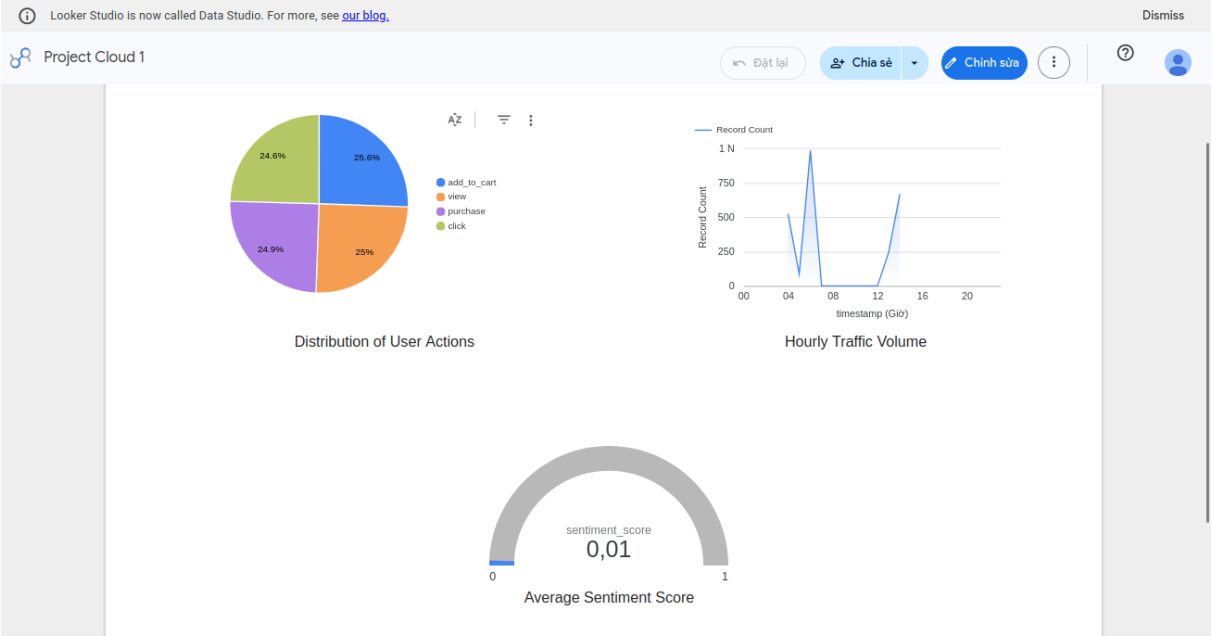

Hình 8: Dashboard Looker Studio hiển thị sentiment gauge, traffic time series, và action pie chart